



UBA
Universidad de Buenos Aires



Departamento de
Ciencias de la Atmósfera y los Océanos
Facultad de Ciencias Exactas y Naturales - Universidad de Buenos Aires



Regionalización estadística de un índice multivariante de estrés térmico mediante técnicas de aprendizaje profundo

Rocío Balmaceda-Huarte, Sol Glatstein, Maria L. Bettolli

Departamento de Ciencias de la Atmósfera y los Océanos
Universidad de Buenos Aires, Argentina
Consejo Nacional de Investigaciones Científicas de Argentina (CONICET)

5 de diciembre 2025

Contenido


- ▶ Introducción
- ▶ Datos & Metodologia
- ▶ Resultados
- ▶ Conclusiones

Introducción

► Contexto

Estrés térmico

 **temperatura** +  **humedad**




Limita la capacidad del cuerpo para regular su temperatura interna

Introducción


► Contexto

Estrés térmico

 **temperatura** +  **humedad**



Limita la capacidad del cuerpo para regular su temperatura interna




Introducción

► Contexto

Estrés térmico

 **temperatura** +  **humedad**




Limita la capacidad del cuerpo para regular su temperatura interna



Ref. Copernicus

Days with at least 'strong heat stress'




Número promedio anual de días con estrés térmico intenso en Europa de 1950 a 2024.

Introducción

► Contexto

Estrés térmico

 **temperatura** +  **humedad**



Limita la capacidad del cuerpo para regular su temperatura interna



Impactos

- Riesgos para la salud
- Reduce la productividad laboral
- Aumento de la demanda energética

Servicios de salud pública y protección civil


Regiones densamente pobladas

Introducción

► Contexto

Estrés térmico

 **temperatura** +  **humedad**




- Riesgos para la salud
- Reduce la productividad laboral
- Aumento de la demanda energética

Servicios de salud
pública y protección
civil

Regiones
densamente
pobladas

Potential Hours of Labour Lost Due to Exposure to Heat

Potential labour hours lost annually due to heat exposure, by sector and by country, Human Development Index (HDI) group, or World Health Organization (WHO) region, from 1990 to 2024



Introducción

► Estrés térmico  temperatura +  humedad




Indices multivariados

Wet Bulb Temperature (TW)

Wet Bulb Globe

Temperature (sWBGT)

Heat Index (HI)



Introducción


► Estrés térmico  temperatura +  humedad



Indices multivariados

Temperatura de bulbo húmedo (TW)

Temperatura de una parcela de aire enfriada adiabáticamente hasta la saturación, a presión constante, mediante la evaporación de agua.



Introducción

► Estrés térmico  **temperatura** +  **humedad**




Indices multivariados

Temperatura de bulbo húmedo (TW)

Temperatura de una parcela de aire enfriada adiabáticamente hasta la saturación, a presión constante, mediante la evaporación de agua.



Capacidad del cuerpo humano para disipar calor a través de la sudoración.




TW $\approx$ 36°C $\rightarrow$ Transpiración deja de ser eficaz $\rightarrow$ el enfriamiento natural del cuerpo se ve afectado

Motivación

► Estrés térmico temperatura + humedad


- + Olas de calor más frecuentes e intensas
 - + Condiciones de estrés térmico
 - + Impacto muy dependiente de las características de cada región
 - Importancia del detalle local para evaluar la vulnerabilidad
-
- ★ La información climática regional sigue siendo limitada en el sur de Sudamérica (SSA).
 - ★ Se necesita información climática más **específica** para la evaluación de impactos




Introducción

► Técnicas de regionalización climática

Modelos Climáticos Globales (GCMs)




Proporcionan
información valiosa
sobre el cambio
climático observado y
futuro



Introducción

► Técnicas de regionalización climática

Modelos Climáticos Globales (GCMs)



Proporcionan información valiosa sobre el cambio climático observado y futuro

Resolución espacial ∞
50-150 km

Modelos Globales

- ✓ Simulación realista de las características de la circulación en gran escala.
- ✓ Simulación realista de la respuesta de la circulación de gran escala a forzantes del sistema climático.
- ✗ Baja resolución espacial (del orden de 100 km)
- ✗ Dificultad para reproducir patrones regionales debido a que no representan los forzantes regionales que modulan la estructura espacial y temporal del clima regional.




Pobre representación de los procesos regionales.
Sesgos sistemáticos.

Forzantes regionales: topografía, cobertura de la vegetación, agua continental, contrastes océano-continente.

Introducción

► Técnicas de regionalización climática

Modelos Climáticos Globales (GCMs)



Técnicas de regionalización climática

Resolución espacial ∞
50-150 km

Información climática local



Necesaria para la evaluación de **impactos** en ciudades, turismo, zonas costeras, etc. y toma de decisiones para **mitigar** el **cambio climático**.



Pobre representación de los procesos regionales.
Sesgos sistemáticos.

Introducción

► Técnicas de regionalización climática

Técnicas Estadísticas (SD)

Se basan en **relaciones empíricas** entre las **variables del modelo** (e.g GCMs) y la **variable** de interés **observada** en puntos locales (o en cuadrícula).

Se obtienen funciones de transferencia que **se aplican** posteriormente a las salidas de los **GCMs** para proyectar el clima futuro con detalle regional.



- ✓ Son poco costosos computacionalmente.
- ✓ Se pueden aplicar a cualquier variable o incluso a índices.

Introducción

► Técnicas de regionalización climática

Técnicas Estadísticas (SD)

Se basan en **relaciones empíricas** entre las **variables del modelo** (e.g GCMs) y la **variable** de interés **observada** en puntos locales (o en cuadrícula).

Se **obtienen funciones de transferencia** que **se aplican** posteriormente a las salidas de los **GCMs** para proyectar el clima futuro con detalle regional.



Perfect Prognosis

Las **observaciones** son utilizadas tanto en la variable predictando (estaciones meteorológicas o bases observadas reticuladas) como en el predictor (**reanálisis**).


Las **variables atmosféricas de gran escala** son utilizadas como predictoras para estimar la variable predictando de interés en superficie.

Introducción

► Técnicas de regionalización climática

Técnicas Estadísticas (SD)

Perfect Prognosis




Las **observaciones** son utilizadas tanto en la variable predictando como en el predictor.

1. Las variables atmosféricas de gran escala son utilizadas como predictoras para estimar la variable predictando de interés en superficie.
2. El modelo estadístico se aplica a los predictores simulados por modelos climáticos.

Introducción

► Técnicas de regionalización climática




Desafíos en la regionalización climática SD

- Se necesitan series de observaciones largas y de calidad.
- Algunos métodos no son consistentes espacialmente y/o físicamente entre más de una variable.
- Requieren una selección de predictores y dominio (métodos tradicionales).
- Condición de estacionariedad (e.g extrapolación a condiciones más cálidas)

Introducción

► Técnicas de regionalización climática

Redes neuronales convolucionales (CNNs)




Configuración DeepESD (CNNs) desarrollada por Baño-Medina et al. (2020) en Europa

Introducción

► Técnicas de regionalización climática

Redes neuronales convolucionales (CNNs)



Configuración DeepESD (CNNs) desarrollada por Baño-Medina et al. (2020) en Europa

- Capacidad para aprender relaciones complejas.
- Manejar espacios predictores de alta dimensión, seleccionando las variables más relevantes.
- Generación de escenarios plausibles de cambio climático (Baño-Medina et al. 2022, González-Abad y Gutiérrez 2025)




Ventajas frente a otros métodos tradicionales de SD

Introducción

► Técnicas de regionalización climática

Redes neuronales convolucionales (CNNs)



Configuración DeepESD (CNNs) desarrollada por Baño-Medina et al. (2020) en Europa

- Capacidad para aprender relaciones complejas.
- Manejar espacios predictores de alta dimensión, seleccionando las variables más relevantes.
- Generación de escenarios plausibles de cambio climático (Baño-Medina et al. 2022, González-Abad y Gutiérrez 2025)




Ventajas frente a otros métodos tradicionales de SD


Introducción

► Técnicas de regionalización climática

Redes neuronales convolucionales (CNNs)



Configuración DeepESD (CNNs) analizada por Baño-Medina et al. (2020) en Europa




Balmaceda-Huarte, Baño-Medina, et al. (2023)

- Adecuación para simular temperaturas extremas en otro dominio.
- Valor agregado frente a otras técnicas SD en el uso de la información de los predictores.
- En el futuro la función de activación intensifica la señal de cambio en algunas regiones de Argentina.

Objetivo

► Estrés térmico + regionalización climática estadística

Explorar el uso de las redes neuronales convolucionales (CNN) como técnica de regionalización climática estadística para estimar la temperatura de bulbo húmedo (TW) en el centro y norte de Argentina.



Norte y centro de Argentina

Objetivo


► Estrés térmico + regionalización climática estadística

Explorar el uso de las redes neuronales convolucionales (CNN) como técnica de regionalización climática estadística para estimar la temperatura de bulbo húmedo (TW) en el centro y norte de Argentina.

Se analizó la sensibilidad en el clima presente a diferentes configuraciones:

- * Función de activación
- * Tamaño del dominio

Para fines de comparación, los modelos CNN se entrenaron y validaron de manera similar para simular la temperatura máxima (Tx).




Norte y centro de Argentina

Datos

► Estrés térmico → TW


- Datos horarios de temperatura del aire (T) y temperatura de rocío (Td) a 2m en 43 estaciones meteorológicas (STN) ubicadas en el centro y norte de Argentina.
- Período 1991-2020 en el trimestre de verano (DEF)




Datos

► Estrés térmico → TW

- Datos horarios de temperatura del aire (T) y temperatura de rocío (Td) a 2m en 43 estaciones meteorológicas (STN) ubicadas en el centro y norte de Argentina.
- Período **1991-2024** en el trimestre de verano (DEF)
- Periodo de REF **percentiles 1995-2014**



Norte y centro de Argentina




Estimo la **TW_x** utilizando la aproximación de Stull (2011) con la T máxima diaria y la HR media diaria

Humedad Relativa (HR): Ta y Td + relación de Clausius-Clapeyron


Datos

► Estrés térmico → TW

- Datos horarios de temperatura del aire (T) y temperatura de rocío (Td) a 2m en 43 estaciones meteorológicas (STN) ubicadas en el centro y norte de Argentina.
- Período **1991-2024** en el trimestre de verano (DEF)
- Periodo de REF **1995-2014**



Norte y centro de Argentina





De la misma forma se estimó TWx del reanálisis ERA5. En este caso se consideró el punto de retícula más cercano a la estación meteorológica.

Datos


► Estrés térmico → TW

P95




SON

DEF




Datos

- Estrés térmico → TW
numero de dias > P95




SON

DEF



Metodología

► Configuración técnica SD → CNN




estandarizados por punto de retícula

En 5 niveles de presión: 250, 500, 700, 850 y 1000 hPa

Reanálisis ERA5 (1deg)
X: 26 predictores


- presión a nivel del mar
- temperatura
- humedad específica
- viento zonal y meridional



Y: variables diarias de las 43 STN superficie
Tx y TWx

Metodología

► Configuración técnica SD → CNN




Modelo	Arquitectura	Función de Activación	Dominio Predictores
CNN10	26-50-25-10	ReLU	Grande
CNN10.L	26-50-25-10	Lineal	Grande
CNN10.SD	26-50-25-10	ReLU	Chico
CNN1.SD	26-50-25-1	ReLU	Chico


Se ajustaron 43 modelos SD con un algoritmo de **optimización** de **Adam** con una **tasa de aprendizaje de $1e-4$** y un tamaño de **batch de 100** para minimizar el efecto de la **función negativa de verosimilitud logarítmica** de una **distribución Gausiana**.

Metodología


► Configuración técnica SD → CNN



TRAINING



TESTING



Resultados


► Entrenamiento CV 1991-2020

Índice	Tx	TWx	Escala temporal
Media	x	x	Diaria
P95	x	x	Diaria
P95p	x	x	Anual
Tx35p	x		Anual
TWx25p		x	Anual

Resultados

► Entrenamiento CV 1991-2020

TWx




Índice	Tx	TWx	Escala temporal
Media	x	x	Diaria
P95	x	x	Diaria
P95p	x	x	Anual
Tx35p	x		Anual
TWx25p		x	Anual

$$\text{BIAS}_{\text{rel}} = \frac{y^{\text{model}} - y^{\text{obs}}}{y^{\text{obs}}}$$

Resultados

► Entrenamiento CV 1991-2020

Tx



Índice	Tx	TWx	Escala temporal
Media	x	x	Diaria
P95	x	x	Diaria
P95p	x	x	Anual
Tx35p	x		Anual
TWx25p		x	Anual


$$\text{BIAS}_{\text{rel}} = \frac{y^{\text{model}} - y^{\text{obs}}}{y^{\text{obs}}}$$

Resultados


► Entrenamiento CV 1991-2020

STN seleccionadas:


- Buenos Aires → 37
- Mendoza → 23
- Iguazú → 2



Tx



TWx





- Obs
- CNNs
- ERA5

Resultados

► Entrenamiento CV 1991-2020

Buenos Aires





Resultados

► Entrenamiento CV 1991-2020

CNN10

lineal

relu



Condición física
 $TWx < Tx$


Resultados

► Entrenamiento CV 1991-2020


Saliency maps (Integrated Gradients, González-Abad et al. 2023) para comprender cómo las CNN utilizan la información de predictores.

Cordoba CNN10

Tx





TWx




Resultados

► Entrenamiento CV + Test 2021-2024 (DEF)



Resultados


► Entrenamiento CV + Test 2021-2024 (DEF)



- Desempeño Test ~ CV
- Mayor acuerdo entre modelos y períodos en TWX que en Tx

Resultados

► Entrenamiento CV + Test 2021-2024 (DEF)




Resultados



► Caso de estudio Verano 2023-2024

ola de calor

Anomalías w.r.t 91-20





Días > P95



Resultados

► Caso de estudio Verano 2023-2024





- Obs
- CNNs
- ERA5
- CNN10
- CNN10.SD

- Evolución temporal capturada por los modelos
- Media del conjunto de CNNs tendió a subestimar levemente la intensidad
- ERA5 subestima mayormente ambas variables
- Tx → CNN10.SD simula mejor los extremos y CNN10 subestima los valores diarios en mayor medida.
- TWx → Menores diferencias entre CNN10 y CNN10.SD

Resultados

► Caso de estudio Verano 2023-2024



- Obs
- CNNs
- ERA5
- CNN10
- CNN10.SD

- Evolución temporal capturada por los modelos aunque no en intensidad (Tx).
- Mayor dispersión entre CNNs durante el evento
- TWx → CNN10.SD simula mejor los extremos y CNN10 subestima los valores diarios en mayor medida.

Reflexiones finales


- ★ Las CNN lograron representar satisfactoriamente tanto los valores medios como los extremos del índice TWx incluyendo un evento de ola de calor, mostrando en varios aspectos un valor agregado frente a ERA5
- ★ Se observó una ventaja de las CNNs frente a ERA5 en estaciones como Mendoza y Buenos Aires.
- ★ Las CNNs se destacaron especialmente en la representación de índices de frecuencia basados en umbrales fijos, relevantes para el estudio de estrés térmico.
- ★ No se identificó una única configuración de las CNN capaz de representar de manera sistemática todos los aspectos de TWx por lo que podría ser conveniente el uso de conjuntos multimodelos.
- ★ En algunos aspectos analizados, las CNN presentaron habilidades mayores simulando TWx que Tx, lo que destaca su capacidad de simular indicadores multivariados

¡Muchas Gracias!

Introducción

► Técnicas de regionalización climática

Redes neuronales convolucionales (CNNs)



Goodfellow et al.,

2016

